

Analyse de Données – Développeur

C5-160512-INFO

2. Tableaux et Espaces

Pr. Carl FRÉLICOT

FST/PAS221 – carl.frelicot@univ-lr.fr



Licence d'Informatique 3ème année

Automne 2021 - La Rochelle



1. Préambule
2. Tableaux et Espaces
 - 2.1 Types de Tableaux
 - 2.2 Espace des Individus – \mathbb{R}^p
 - 2.3 Espace des Variables – \mathbb{R}^n
3. Réduction de la Dimensionnalité
4. Classification Non Supervisée
5. Classification Supervisée



- individus vs variables quantitatives
données dites *vectorielles*


$$X = [X_{ki}]_{k=1,n; i=1,p}$$

nuage de n points en dim. p

Principal Component Analysis

+ éventuellement une variable catégorielle (supervisé)


Linear Discriminant Analysis



- individus vs individus
données non vectorielles
ex. : tableau de distances, proximités, etc

$$D = [d_{kl}]_{k,l=1,n} \text{ où } d_{kl} = d(x_k, x_l)$$

K-Means, Hierarchical Clustering



- 1 variable qualitatives vs 1 variables qualitative
ex : tableau de contingence

Correspondance Analysis

extensible à plus de deux variables qualitatives

modalités x modalités




1. Préambule
2. Tableaux et Espaces
 - 2.1 Types de Tableaux
 - 2.2 Espace des Individus – \mathbb{R}^p
 - 2.3 Espace des Variables – \mathbb{R}^n
3. Réduction de la Dimensionnalité
4. Classification Non Supervisée
5. Classification Supervisée



- individus vs variables quantitatives
données dites *vectorielles*
 $X = [X_{ki}]_{k=1,n; i=1,p}$ nuage de n points en dim. p
- $x_k = [x_{ki}]_{i=1,p}$ où $x_{ki} = \langle x_k, e_i \rangle = {}^t x_k e_i$ e_i unitaires

Produit Scalaire

- $\langle x, y \rangle = {}^t x y = \sum_{i=1}^p x_i \times y_i$ projection
- norme $\|x\| = \sqrt{\langle x, x \rangle}$ dist. à l'origine
- angle $\cos(x, y) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$ proximité
- distance $d(x, y) = \|x - y\|$ euclidienne usuelle



M-Produit Scalaire

- $\langle x, y \rangle_M = {}^t x M y$
en général M définit une **métrique** si M symétrique, définie positive
- cas particuliers usuels : M diagonale, $M = I_p$
- M -norme (carré) $\|x\|_M^2 = {}^t x M x, \dots$ pondération des variables

matrice de produit scalaire

si M symétrique, définie positive

pondération des variables

Comment est définie une variable X_i ?

$$X_i = X e_i$$

Une (nouvelle) variable C_j de vecteur directeur u_j unitaire ?

$$C_j = X u_j$$

Projeter un nuage X dans espace défini par $U = [u_1 u_2 \dots u_q]$?


$$C = X U$$



1. Préambule
2. Tableaux et Espaces
 - 2.1 Types de Tableaux
 - 2.2 Espace des Individus – \mathbb{R}^p
 - 2.3 Espace des Variables – \mathbb{R}^n
3. Réduction de la Dimensionnalité
4. Classification Non Supervisée
5. Classification Supervisée



- individus vs variables quantitatives
données dites *vectorielles*
 $X = [X_{ki}]_{k=1,n; i=1,p}$ nuage de n points en dim. p
- $x_k = [x_{ki}]_{i=1,p}$ où $x_{ki} = \langle x_k, e_i \rangle = {}^t x_k e_i$ e_i unitaires



Produit Scalaire (variables centrées) X'

- $\langle X'_i, X'_j \rangle_{D_n} = {}^t X'_i D_n X'_j = \text{Cov}(X_i, X_j)$
avec la **métrique** $D_n = \frac{1}{n} I_n$ **pondération des individus**
- norme (carré) $\|X'_i\|_{D_n}^2 = {}^t X'_i D_n X'_i = \text{Var}(X_i)$ longueur
- angle $\cos(X'_i, X'_j) = \frac{\langle X'_i, X'_j \rangle_{D_n}}{\|X'_i\|_{D_n} \|X'_j\|_{D_n}} = \langle X''_i, X''_j \rangle_{D_n} = \text{Corr}(X_i, X_j)$ proximité

M-Produit Scalaire

- $\langle x, y \rangle_M = {}^t x M y$
en général M définit une **métrique** si M symétrique, définie positive
- cas particuliers usuels : $M = I$, M diagonale
- M -norme (carré) $\|x\|_M^2 = {}^t x M x, \dots$ pondération des variables

Comment est définie une variable X_i ?

$$X_i = X e_i$$

Une (nouvelle) variable C_j de vecteur directeur u_j unitaire ?

$$C_j = X u_j$$

Projeter un nuage X dans espace défini par $U = [u_1 u_2 \dots u_q]$?

$$C = X U$$



1. Préambule
2. Tableaux et Espaces
 - 2.1 Types de Tableaux
 - 2.2 Espace des Individus – \mathbb{R}^p
 - 2.3 Espace des Variables – \mathbb{R}^n
3. Réduction de la Dimensionnalité
4. Classification Non Supervisée
5. Classification Supervisée