

Licence d'Informatique 3ème année

Analyse de Données Programmeur (C5-160512)

ACP – Solution Mathématique

Carl FRÉLICOT – Dpt Info / Lab MIA

Le problème de l'Analyse en Composantes Principales est un problème d'optimisation sous contrainte(s). Il s'agit de trouver pour la 1ère composante (puis la 2ème, etc), le vecteur directeur u_1 unitaire (puis u_2 , etc) qui la définit, le critère à optimiser étant : la variance projetée qu'il faut maximiser.

On utilise pour cela la *méthode de Lagrange* qui permet ¹, par substitution, d'optimiser une fonction à valeurs dans \mathbb{R} de plusieurs variables ² sous contrainte(s) d'égalité c .

Par exemple, le problème : $\max_u \{g(u) | c(u) = 0\}$ est substitué par $\max_{u,\lambda} \{L(u, \lambda) = g(u) - \lambda c(u)\}$ où $\lambda \in \mathbb{R}$ est appelé *multiplicateur de Lagrange*. La solution est alors tout à fait standard ³ :

$$\begin{cases} \frac{d}{du} L(u, \lambda) = 0 \\ \frac{d}{d\lambda} L(u, \lambda) = 0 = c(u) \end{cases}$$

où $\frac{d}{dx}$ représente la dérivée par rapport à x . Si x est un vecteur, sa dérivée (vectorielle) est le vecteur des dérivées par rapport à chacune de ses composantes ; on l'appelle alors *gradient* et on le note parfois ∇ . Dans notre cas, $\frac{d}{du} L = [\frac{d}{du_i} L]_{i=1,p}$. On montre ⁴ que :

- si a est un vecteur constant de \mathbb{R}^p et $u \in \mathbb{R}^p$, alors $\frac{d}{du} ({}^t a u) = a$
- si u et $v \in \mathbb{R}^p$, et M une matrice carrée d'ordre p , alors $\frac{d}{du} ({}^t u M v) = M v$ et $\frac{d}{du} ({}^t v M u) = {}^t M v$
- en conséquence, pour une forme quadratique $\frac{d}{du} ({}^t u M u) = M u + {}^t M u$,
- et si de plus M est symétrique, il vient $\frac{d}{du} ({}^t u M u) = 2 M u$.

Notez que vous connaissez ces formules en dimension $p = 1$, c'est-à-dire lorsque u est un scalaire, et $M = m$ également. Par ex. la dernière devient $(m u^2)' = 2 m u$.

Pour l'ACP, on doit tout d'abord trouver u_1 qui maximise $g(u_1) = {}^t u_1 V u_1$, à valeurs dans \mathbb{R} , où V est la matrice de covariance ⁵, sous la contrainte $\|u_1\| = 1$ que l'on écrit $c(u_1) = \|u_1\|^2 - 1 = {}^t u_1 u_1 - 1 = 0$. On substitue donc par la recherche de u_1 qui maximise $L(u_1, \lambda_1) = {}^t u_1 V u_1 - \lambda_1 ({}^t u_1 u_1 - 1)$. La solution est alors :

$$\begin{cases} \frac{d}{du_1} L(u_1, \lambda_1) = 0 \\ \frac{d}{d\lambda_1} L(u_1, \lambda_1) = 0 \end{cases} \Leftrightarrow \begin{cases} 2 V u_1 - 2 \lambda_1 u_1 = 0 \\ {}^t u_1 u_1 - 1 = 0 \end{cases} \Leftrightarrow \begin{cases} V u_1 = \lambda_1 u_1 \\ {}^t u_1 u_1 = 1 \end{cases}$$

Dans la 2ème équation on retrouve la contrainte (u unitaire), et la 1ère indique que u_1 est vecteur propre ⁶ de V associé à la (plus grande, voir mon CM) valeur propre λ_1 .

On doit ensuite trouver u_2 qui maximise $g(u_2) = {}^t u_2 V u_2$ sous les contraintes $\|u_2\| = 1$ et $u_2 \perp u_1 \Leftrightarrow u_2 V u_1 = 0$. Il suffit d'introduire deux multiplicateurs de Lagrange (un par contrainte) pour substituer le problème par la recherche de u_2 qui maximise $L(u_2, \lambda_1, \lambda_2) = {}^t u_2 V u_2 - \lambda_2 ({}^t u_2 u_2 - 1) - \lambda_1 ({}^t u_2 V u_1)$. La solution est alors :

$$\begin{cases} \frac{d}{du_2} L(u_2, \lambda_1, \lambda_2) = 0 \\ \frac{d}{d\lambda_1} L(u_2, \lambda_1, \lambda_2) = 0 \\ \frac{d}{d\lambda_2} L(u_2, \lambda_1, \lambda_2) = 0 \end{cases} \Leftrightarrow \begin{cases} 2 V u_2 - 2 \lambda_2 u_2 - \lambda_1 V u_1 = 0 \\ {}^t u_2 u_2 - 1 = 0 \\ {}^t u_2 V u_1 = 0 = {}^t u_1 V u_2 \end{cases}$$

Comme u_1 est vecteur propre de V , la 3ème équation peut s'écrire : ${}^t u_2 (\lambda u_1) = 0 \Leftrightarrow \lambda {}^t u_2 u_1 = 0 \Rightarrow {}^t u_2 u_1 = 0$.

Pré-multiplions la 1ère par ${}^t u_1$: ${}^t u_1 (2 V u_2 - 2 \lambda_2 u_2 - \lambda_1 V u_1) = 0 \Leftrightarrow 2 {}^t u_1 V u_2 - 2 \lambda_2 {}^t u_1 u_2 - \lambda_1 {}^t u_1 V u_1 = 0$.

Le deux premiers termes étant nuls, il faut que $\lambda_1 = 0$.

Ce qui donne dans la 1ère équation : $2 V u_2 - 2 \lambda_2 u_2 = 0 \Leftrightarrow V u_2 = \lambda_2 u_2$, c'est-à-dire que u_2 est aussi vecteur propre de V , associé à la valeur propre λ_2 . Comme u_2 doit maximiser ${}^t u_2 V u_2 = \lambda_2 {}^t u_2 u_2 = \lambda_2$, il s'agit de prendre le vecteur propre associé à la 2ème plus grande valeur propre de V .

Et ainsi de suite jusqu'à la p -ième composante dont le vecteur directeur u_p est vecteur propre de V associé à la p -ième plus grande valeur propre, c'est-à-dire la plus petite. Les composantes principales d'un nuage X sont ainsi définies par les vecteurs propres de sa matrice de covariance, dans l'ordre décroissant des valeurs propres.

¹sous conditions non développées ici, en particulier : dérivabilité par rapport à toutes les variables

²un vecteur $u \in \mathbb{R}^p$ est un objet constitué de p variables

³faites appel à vos souvenirs sur la recherche d'extrema d'une fonction $f(x)$

⁴dans un cours sur les dérivées vectorielles des formes quadratiques

⁵symétrique par définition

⁶voir un cours sur les éléments propres d'une matrice